

Inteligência Artificial

2ª parte do Projeto

Grupo 13

João Nogueira Nº 83488

João Pina Nº 85080

P1-Métodos de Classificação

Escolha de features

Para a escolha de features, testámos cerca de 10 hipóteses e a sua eficácia individualmente. Logo após testámos diferentes combinações das mesmas e chegamos aos melhores valores com as seguintes 5 features: Comprimento da palavra; Somatório do valor utf-8 de cada letra; Valor utf-8 da primeira letra; Valor utf-8 da última letra; Valor utf-8 da letra do meio.

Método de aprendizagem

Entre o `DecisionTreeClassifier` e o `KNeighborsClassifier` decidimos optar pelo `DecisionTreeClassifier` pois é considerado melhor para classificar conjuntos não numéricos e conseguimos melhores valores com este classificador.

Análise e escolha de parâmetros

Quanto à escolha de parâmetros, apenas variamos o `min_samples_split`, sabemos que quando menor este valor maior a probabilidade de ocorrer *overfitting*, mas no caso em questão o grupo de treino e o grupo de teste são iguais decidimos por o mínimo (`min_samples_split = 2`).

P2-Métodos de Regressão

Método de aprendizagem

Após análise dos pontos de teste na representação gráfica fornecida, observámos que o método de aprendizagem mais adequado aos pontos seria o método ***KernelRidgeRegressor***. Após vários testes, decidimos que as 2 melhores variações deste mesmo método, seriam uma em que o parâmetro `kernel = "rbf"` e outra em que `kernel = "polynomial"`.

Análise e escolha de parâmetros

Kernel = "rbf": Os parâmetros a serem testados foram *alpha* e *gamma*, variámos estes valores e para cada um dos testes calculámos os valores que mais se adequavam a cada um deles de modo a ter o melhor resultado possível em cada um deles. Após concluir que conseguíamos aplicar este método a ambos os testes com sucesso encontramos os valores que melhores resultados conseguem em ambos os testes simultaneamente (*alpha* = 0.00001, *gamma* = 0.06202).

Kernel = “polynomial”: Além dos parâmetros testados no caso anterior variámos também o *degree*, concluindo que o valor ideal é obtido com *degree* = 5. Apesar de este ser o segundo melhor método aplicável aos nossos casos de teste, e apesar da boa performance no segundo teste, com este método não nos foi possível alcançar um valor de erro abaixo dos 0.3 requeridos pelo primeiro teste. Assim, usámos os melhores valores para o segundo teste ($\alpha = 0.001$, $\gamma = 0.046$).


P3-Aprendizagem por Reforço

Quanto à função de recompensa, após análise concluímos que, em ambos ambientes, os estados com recompensa = 1 são os estados 0 e 6 e em todos os outros estados a recompensa é 0. Concluímos também que o agente só recebe a recompensa ao realizar uma ação quando o seu estado atual é algum dos referidos anteriormente e não quando chega ao mesmo.


Ao fazer a análise de trajetórias do de ambos ambientes podemos concluir que o agente pode movimentar-se entre 7 estados possíveis (0, 1, 2, 3, 4, 5, 6) e pode mover-se em 2 direções, no caso da ação = 1, o agente movimenta-se em direção ao estado 0 (esquerda no caso da nossa representação) e no caso da ação = 0 o agente movimenta-se em direção ao estado 6 (direita da representação gráfica).

No estado 5 existe uma particularidade uma vez que ao realizar a ação 0 apesar de existir uma grande probabilidade de se deslocar para o estado 6 existe também a possibilidade de ficar no mesmo estado.

Ambiente 1



Ambiente 2



No caso do primeiro ambiente, nos estados 0 e 6 existe a particularidade de serem “estados finais”, ou seja, se o agente se encontrar no estado 0 e a ação escolhida for 1 o agente fica no mesmo estado e o mesmo acontece no estado 6 ao utilizar a ação = 0.

Já no segundo ambiente, no caso do estado 6, ao realizar a ação 0 o mesmo não se mantém no mesmo sítio, em vez disso, movimenta-se de novo para o estado 1.